

PROYECTO FINAL · CURSO DE INTEGRACIÓN CON LLM

Comparador de precios de Gas LP a domicilio

Ficha del caso, arquitectura, decisiones técnicas
y resultados de evaluación

Ficha del caso

Usuario: Un consumidor de Gas LP con tanque estacionario (instalado en su casa o negocio) que quiere decidir a qué distribuidor pedirle que mande un camión (autotanke) a llenarlo, comparando precios entre varias zonas o distribuidores disponibles.

Entrada: Una lista de ubicaciones (entidad/municipio/localidad del catálogo de la CNE) que el consumidor está dispuesto a considerar.

```
{
  "paradas": [
    {"entidad_id": "05", "municipio_id": "035", "localidad_id": "448", "etiqueta": "Torreón (Antonio Guerrero)"},
    {"entidad_id": "05", "municipio_id": "035", "localidad_id": "143", "etiqueta": "Albia"}
  ]
}
```

Salida: Por cada ubicación, los distribuidores disponibles con su precio por litro, más una recomendación en texto sobre a quién conviene pedirle el servicio a domicilio y por qué.


```
{
  "resultados": [
    {
      "parada": {"etiqueta": "Torreón (Antonio Guerrero)"},
      "distribuidores": [
        {"marca_comercial": "GRUPO CENTURION COMBUSTIBLES...", "precio_litro": 10.88}
      ],
      "precio_litro_minimo": 10.88
    }
  ],
  "recomendacion": "Te conviene pedirle el servicio a...",
  "modelo_llm": "gemini-3.5-flash"
}
```

Qué aporta el LLM: Interpreta los precios ya validados y redacta la recomendación en lenguaje natural — no decide qué consultar ni puede inventar cifras que no estén en los datos.

Qué valida el código: Formato de los IDs de ubicación (regex), mínimo 2 ubicaciones, rango razonable de precio ($\$0 < \text{precio_litro} \leq \50), autorización por API key, y reintentos ante fallos intermitentes de la CNE.

Qué pasa si falla: Si la CNE no responde tras 5 intentos → `502 api_externa_no_disponible` ; si ninguna ubicación tiene distribuidores válidos → `404 sin_resultados` ; si los datos de entrada están mal formados → `422 datos_invalidos` / `datos_faltantes` ; sin API key válida → `401 sin_autorizacion` .

Diagrama de arquitectura



Justificación del patrón

Se eligió un **flujo lineal y controlado** (el código decide qué consultar, el LLM solo interpreta) en vez de dar al modelo la capacidad de decidir qué llamar (tool calling / function calling). Los datos vienen de una fuente **regulada por el gobierno mexicano** (CNE), y el valor del servicio depende de que el precio mostrado sea exactamente el reportado oficialmente — no una aproximación que el modelo decida buscar o interpretar por su cuenta.

El LLM entra únicamente **después** de que el código ya validó, consultó y filtró los datos; su única función es redactar la recomendación en lenguaje natural, dirigida a un consumidor que va a pedir el servicio por teléfono o app, a partir de información que ya no puede alterar.

Decisión: precio por autotanke (litro) vs. recipiente (kg)

La CNE reporta dos tarifas distintas para Gas LP en su endpoint de Planta de Distribución: **AutoTanques** (precio por litro, para reparto a domicilio vía camión hacia un tanque estacionario) y **Recipientes** (precio por kilogramo, para consumidores que llevan su propio cilindro a la planta). El proyecto usa **AutoTanques**, ya que el caso final es ayudar a un consumidor que **no se traslada** — decide, desde su casa, a qué distribuidor pedirle que le manden el camión a llenar su tanque estacionario.

Se consideró previamente el escenario de **Recipientes**, para un consumidor que acude en persona a cargar su cilindro; se descartó a favor de este enfoque de reparto a domicilio, más representativo del uso típico de Gas LP en hogares mexicanos.

Hallazgo: inestabilidad de la API de la CNE

La API de la CNE presenta una tasa de fallo intermitente (~30-40% en pruebas) con el error interno "Referencia a objeto no

establecida...". Se implementaron reintentos con backoff exponencial (5 intentos, hasta ~22s) y headers explícitos (`Accept-Language`) que redujeron la tasa de fallo original (~100% sin los headers) pero no la eliminaron por completo. Se considera un riesgo operativo documentado del proveedor, no un defecto del servicio propio.

Evaluación (sesión 5)

Métrica: G-Eval (`FidelidadRecomendacion`), evaluada con el propio Gemini 3.5 Flash como juez vía Vertex AI. Criterio: la recomendación debe identificar al distribuidor con el precio por litro más bajo entre los datos provistos, sin inventar distribuidores, precios o ubicaciones que no aparezcan en el contexto. Umbral: 0.7.

Para los casos 3, 4 y 5 (contrato y manejo de errores) se usan pruebas deterministas con `pytest` , ya que no involucran texto generado por el LLM y deben ser 100% reproducibles.

#	Caso	Método	Resultado esperado	Obtenido	Conclusión
1	Petición válida (Torreón/Albia)	G-Eval	Recomienda al de menor precio, sin inventar datos	PASSED (≥0.7)	El LLM identifica correctamente el precio mínimo real
2	Válida, condición distinta (Saltillo)	G-Eval	Igual que el caso 1, otra ubicación	PASSED (≥0.7)	El criterio generaliza a datos distintos
3	Datos faltantes (<2 paradas)	pytest	422 antes de tocar la CNE/LLM	PASSED	Pydantic bloquea en el borde del sistema
4	Datos inválidos (IDs mal formados)	pytest	422, sin llamada externa	PASSED	El regex rechaza formatos incorrectos
5	Fallo de proveedor (mock)	pytest	502, sin llamar al LLM	PASSED	Aisla el fallo externo del resto del flujo

Evidencia completa: `evidencias/sesion-05/pytest-resultados.txt` y `evidencias/sesion-05/deepeval-resultados.txt` .

Plan de operación (borrador)

Alcance: Servicio de un solo endpoint (`POST /comparar-ruta`) para uso interno/demostrativo. No incluye autenticación de usuarios finales más allá de la API key compartida, ni persistencia de datos.

Acceso: Requiere credenciales propias de cada operador: cuenta de servicio de Google Cloud con rol `Vertex AI User` , cuenta en Langfuse, y la API key propia del servicio.

Costo estimado: Dominado por las llamadas a Gemini 3.5 Flash vía Vertex AI (tarifa por token) y, en menor medida, por el volumen de trazas en Langfuse. La consulta a la CNE no tiene costo. Con el volumen de este proyecto, el costo se mantuvo dentro del nivel gratuito/mínimo de ambos servicios.

Mantenimiento:

- Revisar periódicamente que el endpoint de la CNE siga vigente — ya cambió una vez de dominio (de `cre.gob.mx` a `cne.gob.mx`) tras la disolución de la CRE en 2025.
- Vigilar la disponibilidad del modelo `gemini-3.5-flash` en la región de Vertex AI configurada.

Responsables: [Tu nombre] — desarrollo, configuración y mantenimiento del servicio.

Qué hacer ante un fallo:

- **Fallo de la CNE** (~30-40% intermitente): el servicio reintenta automáticamente; si persiste, responde 502 de forma controlada.
- **Fallo de Gemini/Vertex AI** (cuota excedida, 429): reintentar más tarde o revisar el tier de facturación.
- **Fallo de Langfuse:** no bloquea el servicio, pero se pierde trazabilidad — revisar las credenciales en `.env` .